Procesamiento Datos tiempo real Apache Nifi

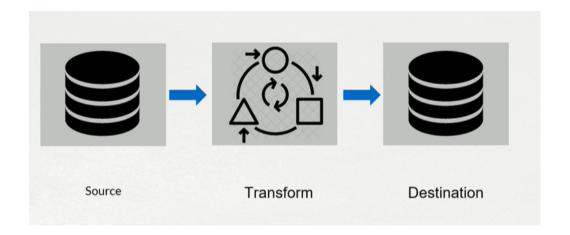
leoria	1
Qué es un flujo de datos (Dataflow)	1
Qué es Apache Nifi	2
Programación Basada en el Flujo (FBP)	2
¿Qué es el Nifi Flow?	2
FlowFiles	3
Práctica	3
Instalación	3
Creación flujo sencillo	7
Generar FlowFile	15
Reemplazar datos	18

Teoría

Qué es un flujo de datos (Dataflow)

https://www.youtube.com/watch?v=JARoqBDSakl&ab channel=AprenderBigData

Movimiento de datos/contenidos de un origen a un destino. Los datos pueden ser CSV, JSON, XML, HTTP, imagen, video, etc...



Qué es Apache Nifi

Proyecto de Apache diseñado para automatizar el movimiento de datos. Permite operaciones de extracción, transformación y carga de datos.

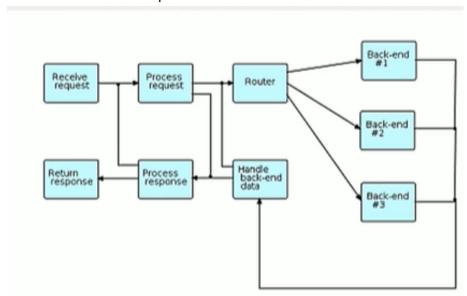
Interfaz web de Apache Nifi Interfaz potente e intuitiva Diseñar y configurar flujos de datos de forma visual Arrancar y para los procesos del flujo de datos Monitorizar el estado de los procesos y los posibles errores que se produzcan

Programación Basada en el Flujo (FBP)

- Nifi está basado en la programación basada en el flujo (FBP)
- Aplicaciones como redes de procesos de "caja negra".

En caso de nifi, estas cajas negras, serían los procesadores.

El intercambio de datos entre estos procesadores se hace mediante conexiones, que se define externamente al procesador



¿Qué es el Nifi Flow?

Es la topología que definimos en Nifi. Definición del flujo de datos que que se implementa en apache Nifi.

Indica la forma en la que se deben de gestionar los datos

FlowFiles

Paquete de datos que viaja por el flujo de Nifi (ficheros de datos que en Nifi los llama FlowFiles).

Se compone:

- Contenido
- Atributos : información sobre el contenido

Ciclo de vida del FlowFile

Persistencia en disco

Se transfiere por referencia

Un nuevo FlowFile se crea cuando el contenido de un FlowFile existente se modifica o se ingesta nuevos datos

Ciclo de vida del FlowFile

Persistencia en disco

Se transfiere por referencia

Un nuevo FlowFile se crea cuando el contenido de un FlowFile existente se modifica o se ingesta nuevos datos

La modificación de los atributos de un FlowFile existente no hace que se cree un nuevo FlowFile

Práctica

Instalación

Instalar Apache Nifi:

https://nifi.apache.org/download.html



Releases

- . 1.16.2
 - o Released May 25, 2022
 - Sources:
 - nifi-1.16.2-source-release.zip (asc, sha256, sha512)
 - Binaries
 - nifi-1.16.2-bin.tar.gz (asc, sha256, sha512)
 - nifi-1.16.2-bin.zip (asc, sha256, sha512)
 - nifi-toolkit-1.16.2-bin.tar.gz (asc, sha256, sha512)
 - nifi-toolkit-1.16.2-bin.zip (asc, sha256, sha512)
 - nifi-stateless-1.16.2-bin.tar.gz (asc, sha256, sha512)
 - Release Notes
 - · Migration Guidance

Elegimos el más reciente Descomprimimos y abrimos en bin

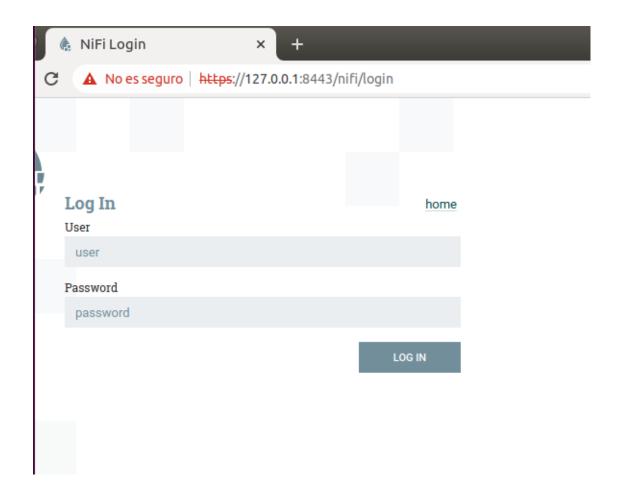
1. Iniciar Nifi:

Windows: "run-nifi.bat" Linux/Mac: "nifi.sh start"

En caso de estar en Linux o Mac , tenemos que ir a ese directorio de bin en la línea de comando y poner "**nifi.sh star**".

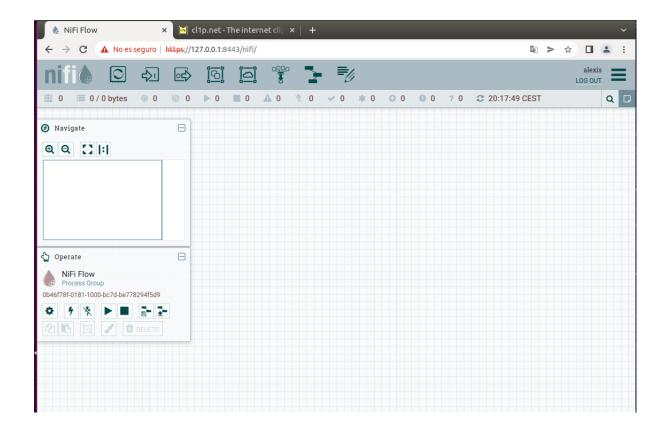
Interfaz web

Nos pide un login p default





```
root@alexis-VirtualBox:/home/alexis/Descargas/nifi-1.16.2/bin# ./nifi.sh set-single-user-credenti
als alexis 12345678901234
Java home: /usr/lib/jvm/java-8-openjdk-amd64
NiFi home: /home/alexis/Descargas/nifi-1.16.2
Bootstrap Config File: /home/alexis/Descargas/nifi-1.16.2/conf/bootstrap.conf
Login Identity Providers Processed [/home/alexis/Descargas/nifi-1.16.2/./conf/login-identity-prov
iders.xml]
root@alexis-VirtualBox:/home/alexis/Descargas/nifi-1.16.2/bin#
-<loginIdentityProviders>
               Single User Login Identity Provider supporting automated generation of Username and Passwork
               The provider will write the following log messages when 'Username' and 'Password' are empty:
               Generated Username [USERNAME]
               Generated Password [PASSWORD]
               The 'Username' will be a random UUID and the 'Password' will be stored using bcrypt hashing
  -----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------
       <identifier>single-user-provider</identifier>
     -<class>
         org.apache.nifi.authentication.single.user.SingleUserLoginIdentityProvider
       </class>
       roperty name="Username">alexis
     ----Password">
         $2b$12$0Asr6i0Y4CBn.5Q9VoP.ge8qeGt0ykbcjQMcqYTk8aj.c/NUAf6sm
       </property>
    -<!--
                    A No es seguro https://127.0.0.1:8443/nifi/login
                 Log In
                                                                                        home
                 User
                   alexis
                 Password
                                                                                  LOG IN
```



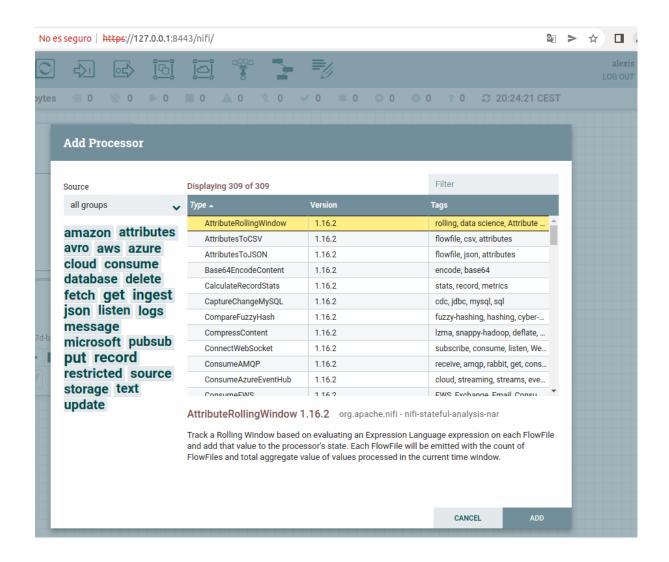
Creación flujo sencillo

Cogemos un archivo de un origen (nuestro ordenador , de un directorio concreto) y lo va a mover sin realizar ningún tipo de transformación a un destino diferente.

Arrastramos un procesador



Nos abre esta ventana, todas estas distintas opciones para utilizar

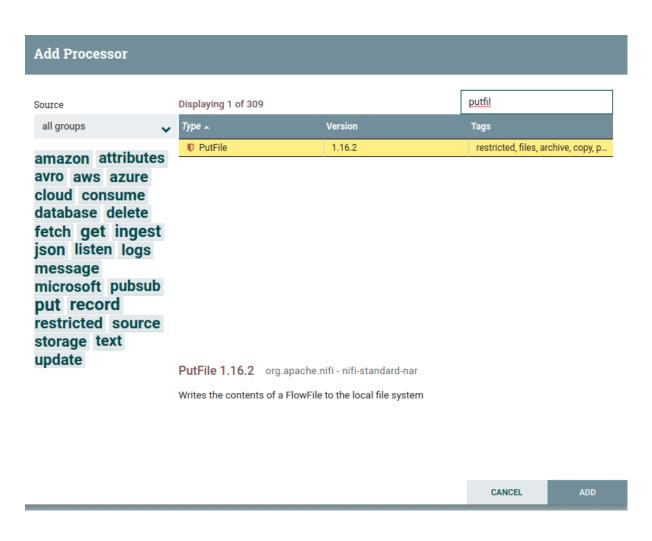


Ponemos dos procesadores de tipos GetFile y Putfile

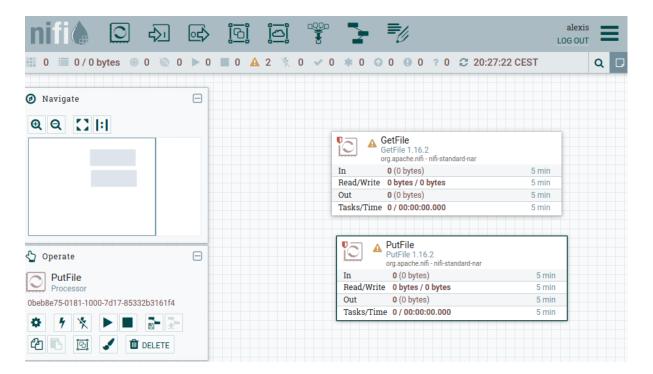
Add Processor



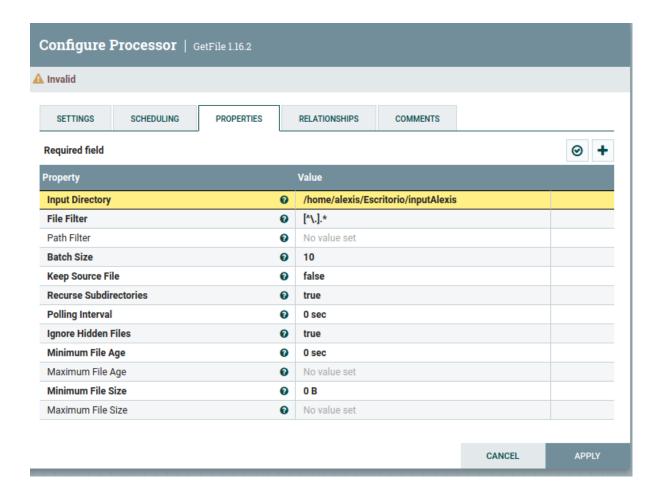
CANCEL

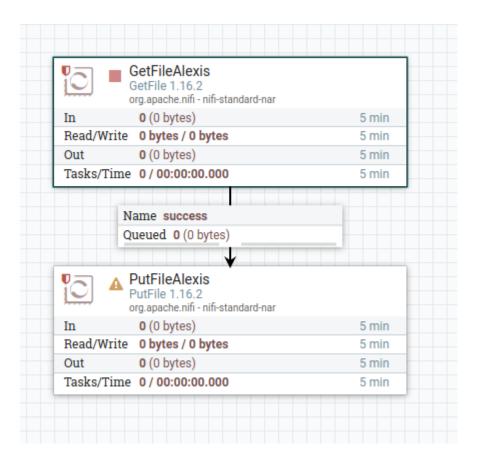


Ya tenemos los dos procesadores

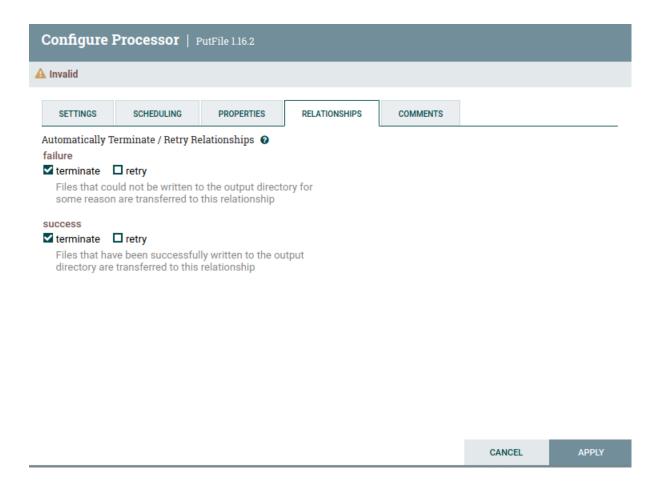


Le pasamos el directorio de las carpetas que vamos a utilizar para este proceso de datos.



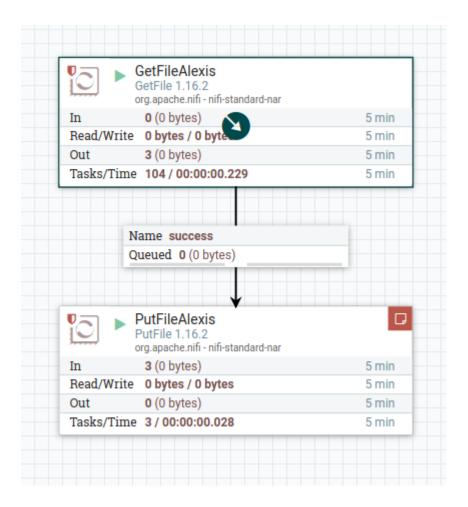


Nos da una advertencia en el de abajo y click derecho configuración, marcamos que cuando acabe o haya algún error, que termine la relación



Los arrancamos

Y todos los ficheros que creamos en Input, al instante los pasa al output

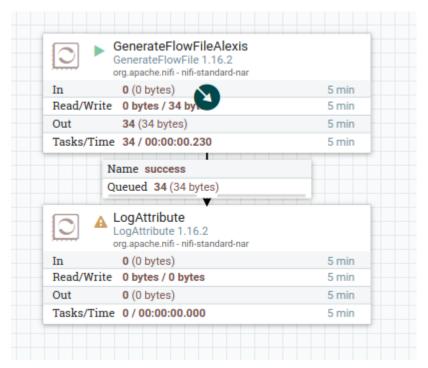




Esta herramienta nos da la opción de tiempo para hacer este proceso, una actualización ya sea de segundos o minutos .

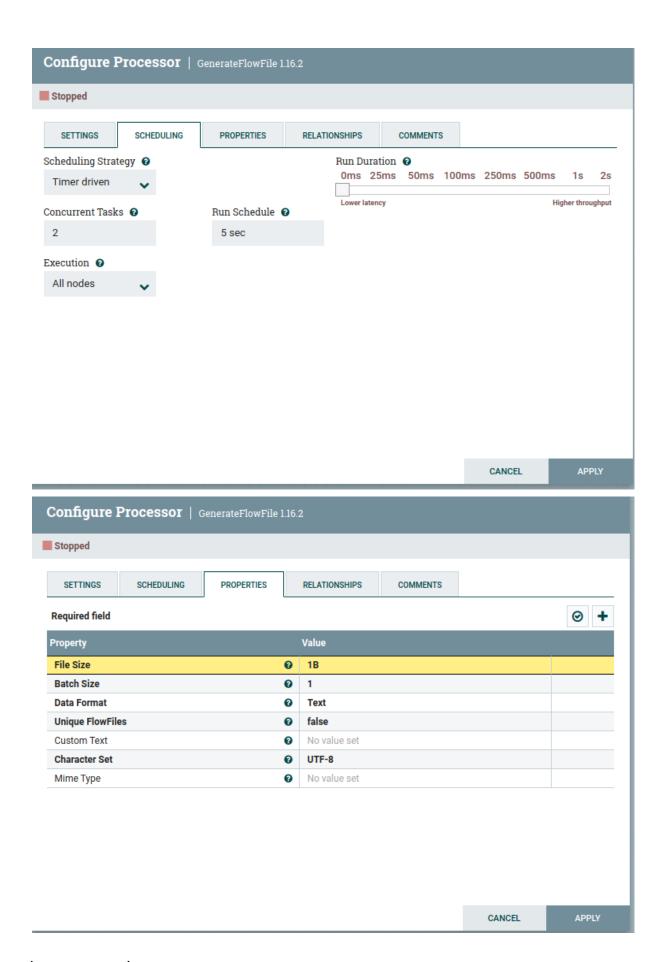
Generar FlowFile

Procesador de tipo GenerateFlowFile más un LogAtrtribute que vale para leer y recopilar datos



En configuraciones

Configuración de tiempo de **5 segundos** para que genere un carácter y **2 Task**. El tamaño **1B** para generar un único carácter

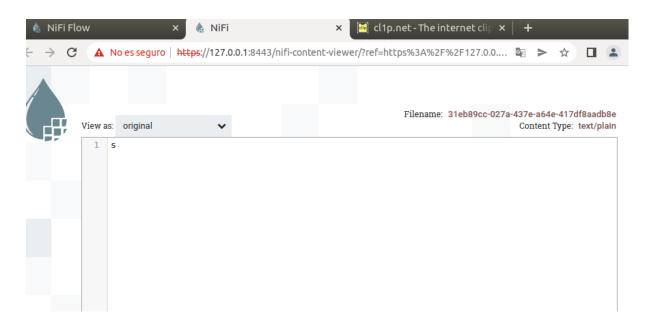


success

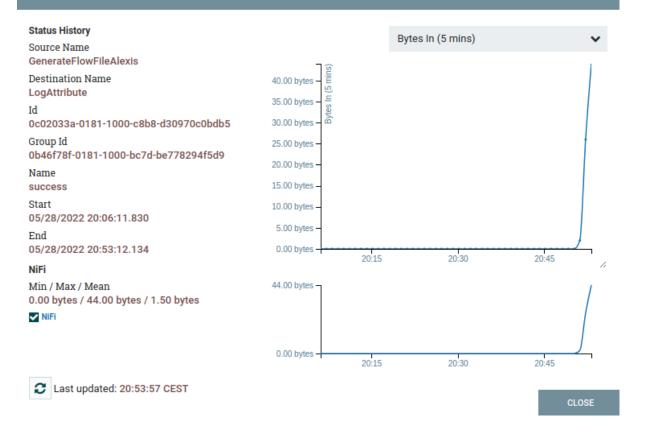
Displaying 44 of 44 (44.00 bytes)

	Position	UUID	Filename	File Size	Queued Duration	Lineage Duration	Penalized	
0	1	31eb89cc-027a	31eb89cc-027a	1.00 bytes	00:03:11.514	00:03:11.522	No	≛ ⊚ 🖺
0	2	29c0522a-71ac	29c0522a-71ac	1.00 bytes	00:03:06.458	00:03:06.458	No	≛ ⊚ Ľ
0	3	a175fafa-e547	a175fafa-e547	1.00 bytes	00:03:01.451	00:03:01.451	No	± ⊚ Ľ
0	4	7769a047-53a7	7769a047-53a7	1.00 bytes	00:02:56.447	00:02:56.447	No	≛ ⊚ Ľ
0	5	50e9850a-25c3	50e9850a-25c3	1.00 bytes	00:02:51.444	00:02:51.444	No	≟ ⊚ Ľ
0	6	95b2f394-f3c3	95b2f394-f3c3	1.00 bytes	00:02:46.442	00:02:46.442	No	≛ ⊚ Ľ
0	7	4dab4ba6-a62c	4dab4ba6-a62c	1.00 bytes	00:02:41.440	00:02:41.440	No	≛ ⊚ Ľ
0	8	942cecc1-f005	942cecc1-f005	1.00 bytes	00:02:36.435	00:02:36.435	No	≛ ⊚ 🖺
0	9	330887ee-44ad	330887ee-44ad	1.00 bytes	00:02:31.433	00:02:31.434	No	≛ ⊚ 🖺
0	10	7aed90a8-0f8e	7aed90a8-0f8e	1.00 bytes	00:02:26.424	00:02:26.424	No	≛ ⊚ Ľ
0	11	c6df1ed0-13f1	c6df1ed0-13f1	1.00 bytes	00:02:21.423	00:02:21.423	No	≛ ⊚ Ľ
0	12	25eca40c-f812	25eca40c-f812	1.00 bytes	00:02:16.421	00:02:16.421	No	≛ ⊚ 🖺
0	13	2c49c747-3f41	2c49c747-3f41	1.00 bytes	00:02:11.419	00:02:11.419	No	≛ ⊚ Ľ
0	14	9ce7fbfa-f96c-4	9ce7fbfa-f96c-4	1.00 bytes	00:02:06.415	00:02:06.415	No	≛ ⊚ 🖺
0	15	039d03c1-2804	039d03c1-2804	1.00 bytes	00:02:01.407	00:02:01.408	No	≛ ⊚ Ľ
0	16	7475d3fd-2b3e	7475d3fd-2b3e	1.00 bytes	00:01:56.397	00:01:56.397	No	≛ ⊚ Ľ
0	17	10060643-6b62	10060643-6b62	1.00 bytes	00:01:51.395	00:01:51.395	No	≛ ⊚ 🖺
0	18	79d09641-9b13	79d09641-9b13	1.00 bytes	00:01:46.393	00:01:46.393	No	≛ ⊚ 🖺
0	19	a8d2a280-97c9	a8d2a280-97c9	1.00 bytes	00:01:41.392	00:01:41.392	No	≛ ⊚ 🖺
0	20	9107b55a-5443	9107b55a-5443	1.00 bytes	00:01:36.386	00:01:36.387	No	.
0	21	88c59f01-05d4	88c59f01-05d4	1.00 bytes	00:01:31.383	00:01:31.384	No	≛ ⊚ Ľ
0	22	00fc5bf2-c12a	00fc5bf2-c12a	1.00 bytes	00:01:26.378	00:01:26.378	No	≛ ⊚ 🖺
0	23	d3d4d02a-566b	d3d4d02a-566b	1.00 bytes	00:03:11.521	00:03:11.522	No	.
0	24	8cba97d3-203e	8cba97d3-203e	1.00 bytes	00:03:06.491	00:03:06.492	No	≛ ⊚ Ľ
0	25	5872e1a7-7793	5872e1a7-7793	. 1.00 bytes	00:03:01.487	00:03:01.487	No	≛ ⊚ Ľ

Le damos al icono del ojo y nos abre otra pestaña donde nos muestra el dato generado

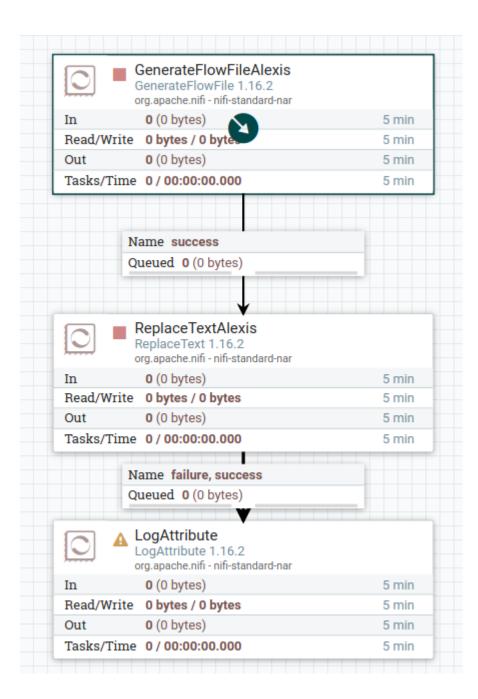


Status History

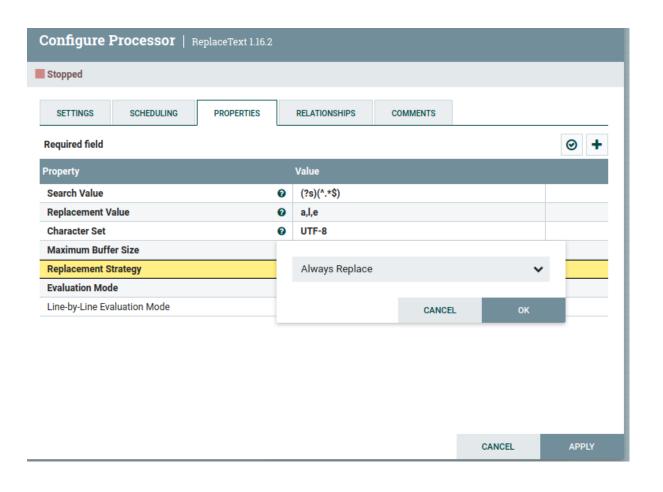


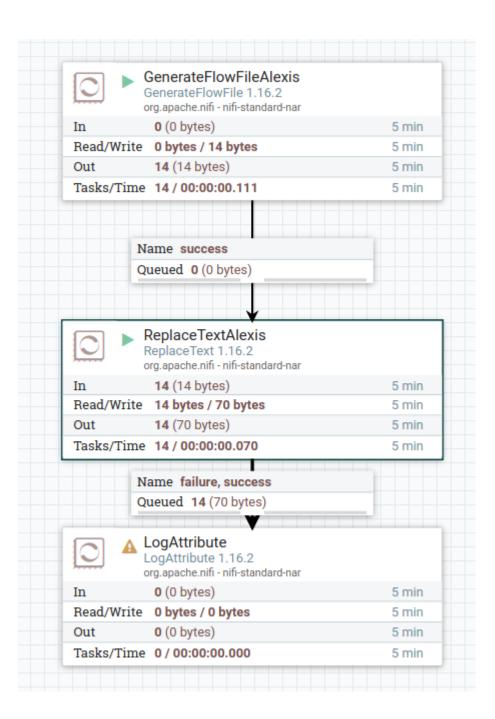
Reemplazar datos

Añadimos otro proceso de remplazar los datos generados



Configuración



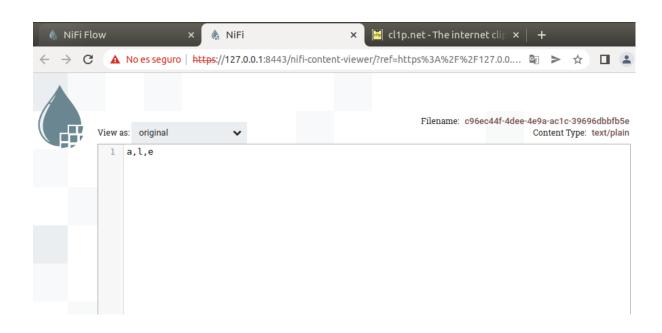




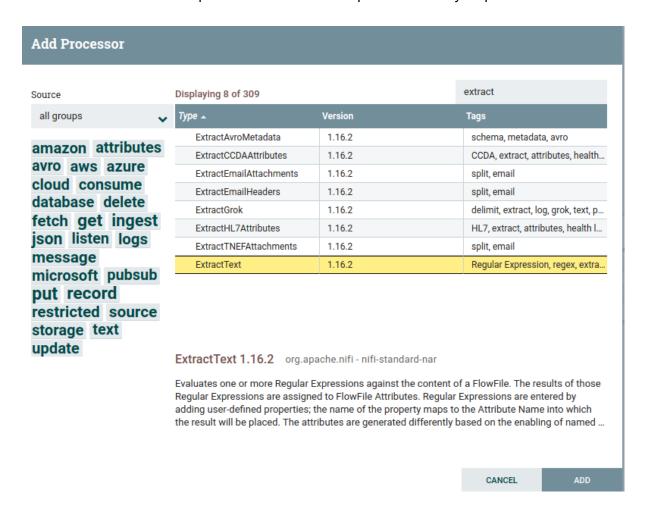
failure, success



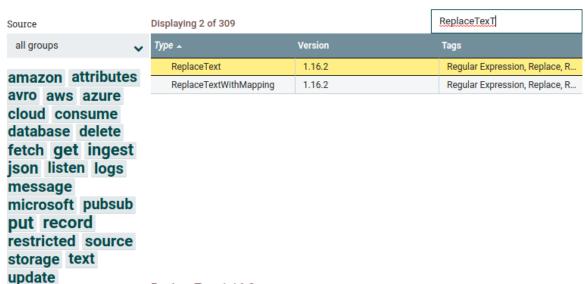
Reemplaza por lo incorporado en la configuración



Añadimos a lo anterior dos procesadores más. De tipo ExtractText y ReplaceText



Add Processor



ReplaceText 1.16.2 org.apache.nifi - nifi-standard-nar

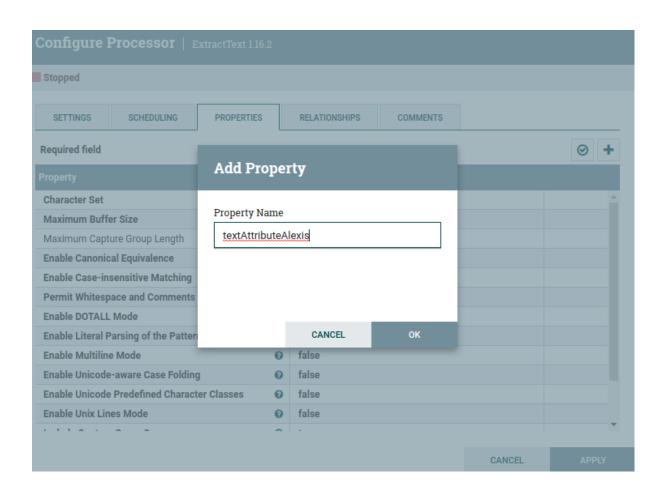
Updates the content of a FlowFile by evaluating a Regular Expression (regex) against it and replacing the section of the content that matches the Regular Expression with some alternate value.

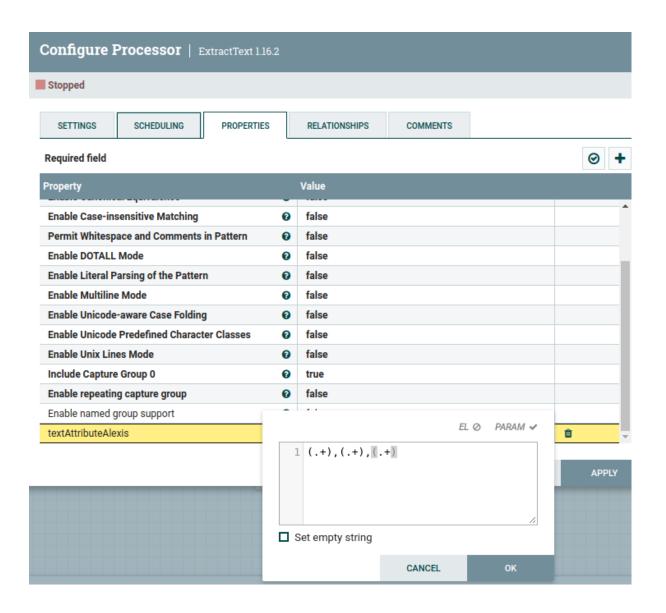
Añadimos las conexiones



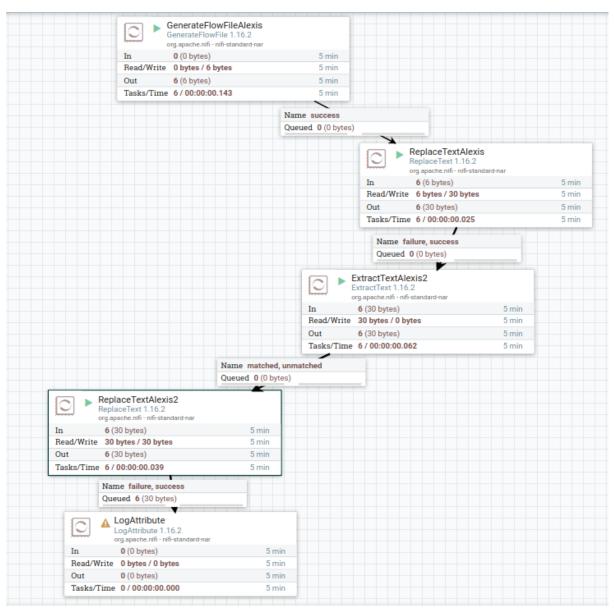
Create Connection SETTINGS DETAILS From Processor To Processor ReplaceTextAlexis2 ExtractTextAlexis2 ExtractText ReplaceText Within Group Within Group NiFi Flow NiFi Flow For Relationships matched unmatched CANCEL

Nos vamos a la configuración de ExtractTextAlexis2 y en propiedades le damos a crear nuevo atributo





Run todos los procesos



Generas FlowFile , reemplazas lo generado.

Extraes lo reemplazado y observamos con el atributo creado

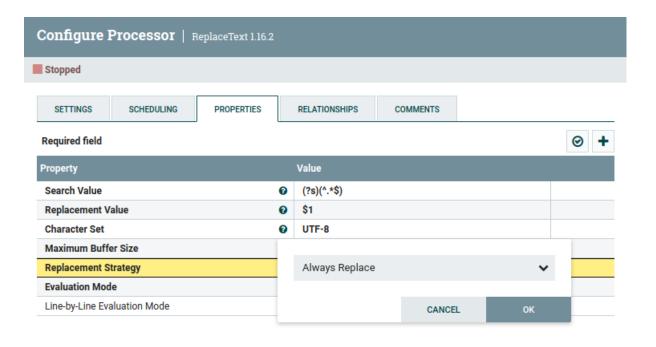
failure, success

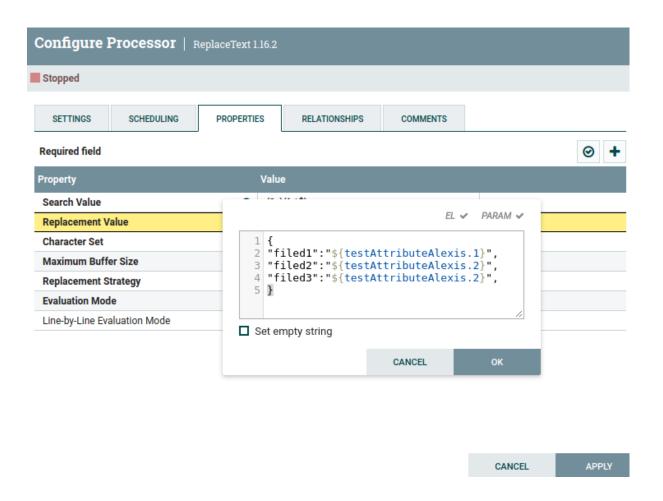
Displaying 100 of 112 (560.00 bytes) The source of this queue is currently I File Size **Queued Duration** Lineage Duration b1891859-46cb-4bad-b... b1891859-46cb-4bad-b... 5.00 bytes 00:10:44.822 0 1 00:10:38.500 2 16a17485-3856-4af4-b... 5.00 bytes 00:10:44.821 0 16a17485-3856-4af4-b... 00:10:38.485 3 6b4dfbb0-8ff3-4e41-b5... 6b4dfbb0-8ff3-4e41-b5... 5.00 bytes 00:10:34.713 00:10:34.750 4 fefe5972-eaa4-4c7d-88... 5.00 bytes 00:10:29.732 00:10:29.749 0 fefe5972-eaa4-4c7d-88... 4e6e8828-dd59-40ef-a... 4e6e8828-dd59-40ef-a... 5.00 bytes 00:10:24.699 00:10:24.747 6 2fa39baa-d43e-4b4f-86... 2fa39baa-d43e-4b4f-86... 5.00 bytes 00:10:19.704 00:10:19.733 0 cd2c9d48-bf61-4dac-9... cd2c9d48-bf61-4dac-9... 5.00 bytes 00:10:14.699 00:10:14.732 8 b479748d-0ee2-4b31-b... b479748d-0ee2-4b31-b... 5.00 bytes 00:10:09.700 00:10:09.728 0 9 0 50283b86-4ecf-45b2-a... 50283b86-4ecf-45b2-a... 5.00 bytes 00:10:04.691 00:10:04.725 10 0a8b9cc1-a7aa-477f-bf... 0a8b9cc1-a7aa-477f-bf... 5.00 bytes 0 00:09:59.685 00:09:59.723 11 488a1613-b4ef-421c-8... 488a1613-b4ef-421c-8... 5.00 bytes 00:09:54.684 00:09:54.720 0 12 3935e093-e175-452c-b... 3935e093-e175-452c-b... 5.00 bytes 00:09:44.658 00:09:44.713 0 13 5cdaeff3-a19c-48f7-ae... 5cdaeff3-a19c-48f7-ae... 5.00 bytes 00:09:39.684 00:09:39.701 4cb7259a-74e8-4a50-a... 0 14 4cb7259a-74e8-4a50-a... 5.00 bytes 00:09:24.664 00:09:24.692 15 5d751cf7-13c5-4bb7-9... 5d751cf7-13c5-4bb7-9... 5.00 bytes 00:09:19.633 00:09:19.664 9e8a36de-b407-403a-a... 00:09:14.661 0 16 9e8a36de-b407-403a-a... 5.00 bytes 00:09:14.649 0 17 ce29d5bd-bd26-4a8b-8... ce29d5bd-bd26-4a8b-8... 5.00 bytes 00:09:09.636 00:09:09.660

Los detalles que nuestro atributo creado y la extracción.



Por último el proceso del último Replace, que lo reemplace tipo Json





Le damos a descargar el flowFile generado reemplazandolo con formato json

failure, success

Displaying 40 of 40 (1.09 KB)

	s currently running. This listing may no long
--	---

	Position	UUID	Filename	File Size	Queued Duration	Lineage Duration	Penalized	
0	16	21e13eaf-0ff4-4e5c-a8	21e13eaf-0ff4-4e5c-a8	28.00 bytes	00:00:30.856	00:00:30.887	No	± ⊚ Ľ
0	17	591c877a-16cd-4d13-9	591c877a-16cd-4d13-9	28.00 bytes	00:00:25.858	00:00:25.886	No	≛ ⊚ Ľ
0	18	1a7e5f59-4b94-414d-8	1a7e5f59-4b94-414d-8	28.00 bytes	00:00:20.878	00:00:20.886	No	.
0	19	d6b9b068-5d78-4812-a	d6b9b068-5d78-4812-a	28.00 bytes	00:00:20.867	00:00:20.886	No	≛ ⊚ 🖺
0	20	742280f7-7b85-4c0e-a	742280f7-7b85-4c0e-a	28.00 bytes	00:00:15.860	00:00:15.884	No	≛ ⊚ 🖺
0	21	976497be-4d38-4750-9	976497be-4d38-4750-9	28.00 bytes	00:00:10.865	00:00:10.883	No	≛ ⊚ 🖺
0	22	29395bc0-b251-41c1-8	29395bc0-b251-41c1-8	28.00 bytes	00:00:05.854	00:00:05.880	No	≛ ⊚ 🖺
0	23	f752f82c-2ee5-4407-8f	f752f82c-2ee5-4407-8f	28.00 bytes	00:01:35.004	00:01:40.907	No	≛ ⊚ Ľ
0	24	398d03a6-dee5-429f-9	398d03a6-dee5-429f-9	28.00 bytes	00:01:34.996	00:01:40.906	No	≛ ⊚ 🖺
0	25	1c9deda8-39aa-44c3-8	1c9deda8-39aa-44c3-8	28.00 bytes	00:01:30.883	00:01:30.905	No	≛ ⊚ Ľ
0	26	e2b125c5-a84c-48a2-b	e2b125c5-a84c-48a2-b	28.00 bytes	00:01:25.871	00:01:25.901	No	≛ ⊚ Ľ
0	27	72dd5510-18cf-4311-9	72dd5510-18cf-4311-9	28.00 bytes	00:01:20.875	00:01:20.900	No	≛ ⊚ 🖆
0	28	7a9c8679-78b9-4d81-9	7a9c8679-78b9-4d81-9	28.00 bytes	00:01:15.888	00:01:15.899	No	≛ ⊚ 🖺
0	29	49cf26d0-8598-4645-8	49cf26d0-8598-4645-8	28.00 bytes	00:01:10.883	00:01:10.899	No	≛ ⊚ 🖆
0	30	d6ed7676-8c4d-4346-a	d6ed7676-8c4d-4346-a	28.00 bytes	00:01:05.876	00:01:05.897	No	盐 ◎ 🖺
0	31	16e01bfb-a5d0-4afe-b5	16e01bfb-a5d0-4afe-b5	28.00 bytes	00:01:00.882	00:01:00.896	No	≛ ⊚ Ľ
0	32	4141af8e-f49a-4468-83	4141af8e-f49a-4468-83	28.00 bytes	00:00:55.877	00:00:55.895	No	≛ ⊚ Ľ
0	33	974fa9b5-1ff3-4516-89	974fa9b5-1ff3-4516-89	28.00 bytes	00:00:45.875	00:00:45.892	No	≛ ⊚ Ľ
0	34	da2ddac0-980c-4909-8	da2ddac0-980c-4909-8	28.00 bytes	00:00:40.874	00:00:40.890	No	± ⊚ Ľ

